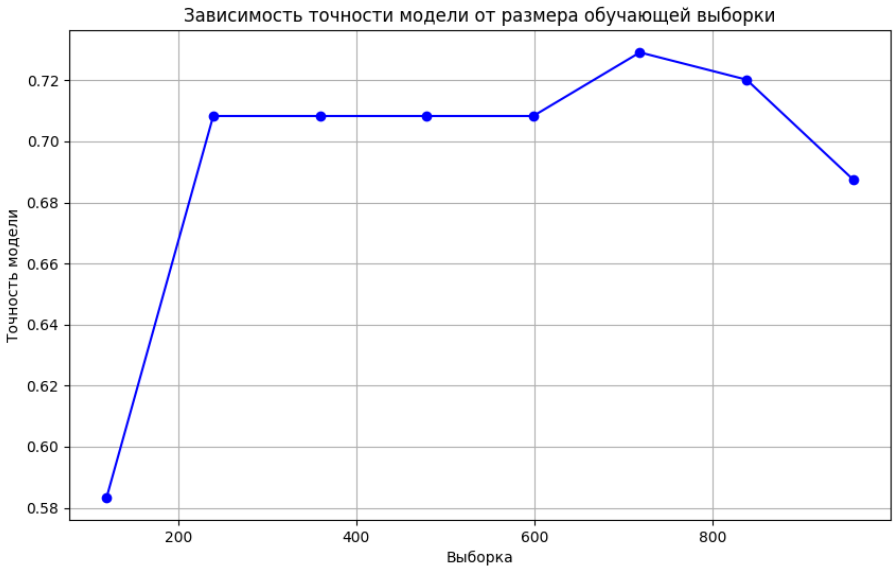
Группа: 5130904/20102

Студент: Шестаков Иван

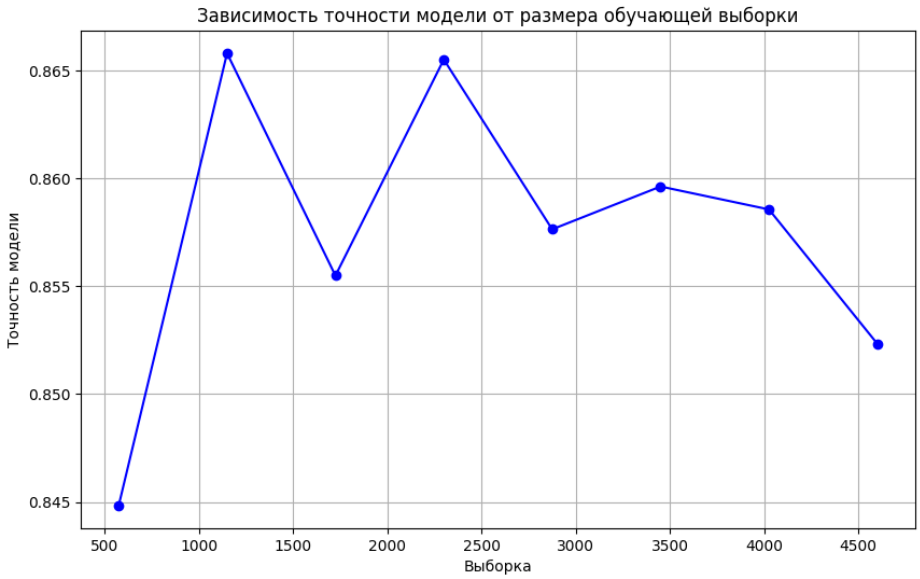
Отчет по 1-ой лабораторной работе

1. Исследуйте, как объем обучающей выборки и количество тестовых данных, влияет на точность классификации в датасетах про крестики-нолики (tic_tac_toe.txt) и о спаме e-mail сообщений (spam.csv) с помощью наивного Байесовского классификатора. Постройте графики зависимостей точности на обучающей и тестовой выборках в зависимости от их соотношения.

   Так выглядит график зависимости точности модели от размера обучающей выборки (tic-tac-toe.txt)



   Так выглядит график зависимости точности модели от размера обучающей выборки (spam.csv)



Графики отличаются, поэтому лучше рассмотреть их по отдельности. График для игры крестики-нолики имеет наибольшую точность (73%) при выборке в 720 элементов. Далее мы видим, что точность начинает падать.

График же для спама имеет максимальную точность (86,6%) при выборке примерно в 1200 элементов. Далее точности колеблется, но не сильно, а концу начинает падать.

Вывод: точность модели зависит не только от объема данных, но и от их качества, структуры и способа разбиения.

2. Сгенерируйте 100 точек с двумя признаками X1 и X2 в соответствии с нормальным распределением так, что одна и вторая часть точек (класс -1 и класс 1) имеют параметры: мат. ожидание X1, мат. ожидание X2, среднеквадратические отклонения для обеих переменных, соответствующие вашему варианту (указан в таблице). Построить диаграммы, иллюстрирующие данные. Построить Байесовский классификатор и оценить качество классификации с помощью различных методов (точность, матрица ошибок, ROC и PR-кривые). Является ли построенный классификатор «хорошим»?

   Вариант:

   Матем. ожид. X1 (класс -1) = 24

   Матем. ожид. X2 (класс -1) = 16

   СКО (класс -1) = 3

   Матем. ожид. X1 (класс 1) = 11

   Матем. ожид. X2 (класс 1) = 6

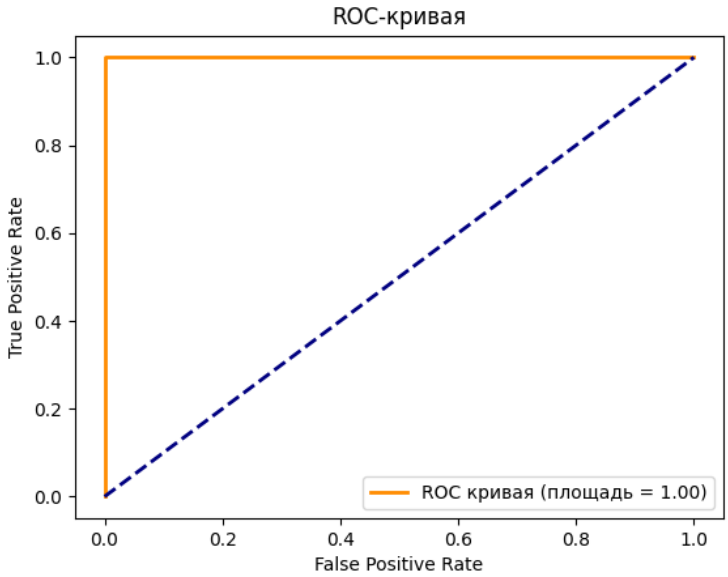
   СКО (класс 1) = 2

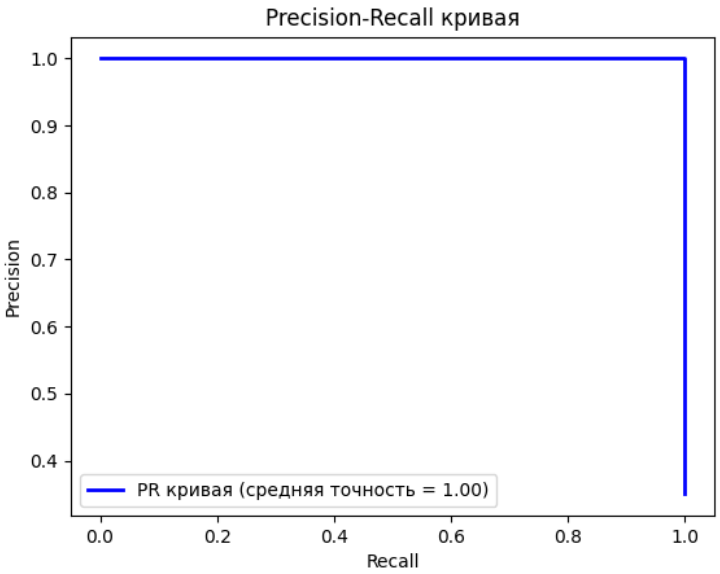
   Количество элементов (класс -1) = 60

   Количество элементов (класс 1) = 40









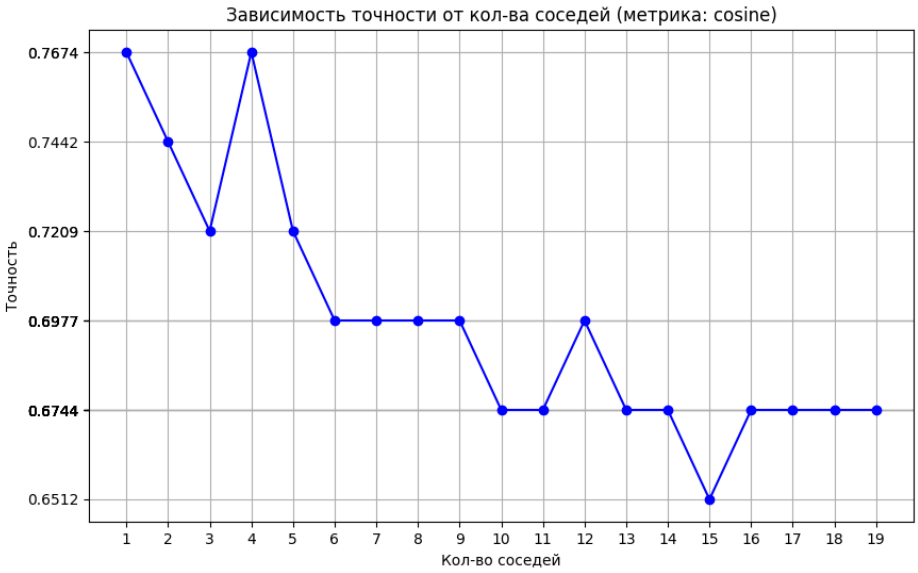
Вывод: на графике видно, что 2 класса достаточно сильно разделены. Это связано с тем, что мат. ожидания признаков прилично разнятся, а ско достаточно маленькое. На матрице ошибок видно, что точность модели 100% по причинам, которые я описал выше. Также мы видим, что ROC-кривая и PR-кривая имеют идеальную форму. Для данных, которые имеют такие же распределение, мат. ожидания и ско, получившийся классификатор является хорошим.

3. Постройте классификатор на основе метода k ближайших соседей для обучающего множества Glass (glass.csv). Посмотрите заголовки признаков и классов. Перед построением классификатора необходимо также удалить первый признак Id number, который не несет никакой информационной нагрузки.
    a. Постройте графики зависимости ошибки классификации от количества ближайших соседей.
    b. Определите подходящие метрики расстояния и исследуйте, как тип метрики расстояния влияет на точность классификации.
    c. Определите, к какому типу стекла относится экземпляр с характеристиками: RI =1.516 Na =11.7 Mg =1.01 Al =1.19 Si =72.59 K=0.43 Ca =11.44 Ba =0.02 Fe =0.1









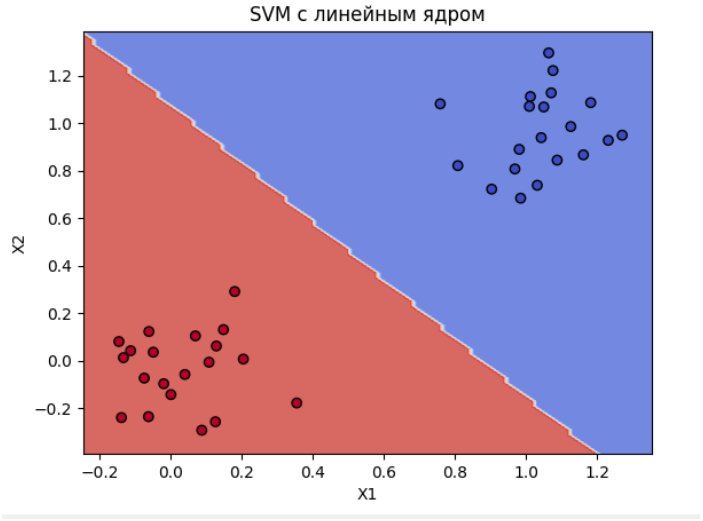


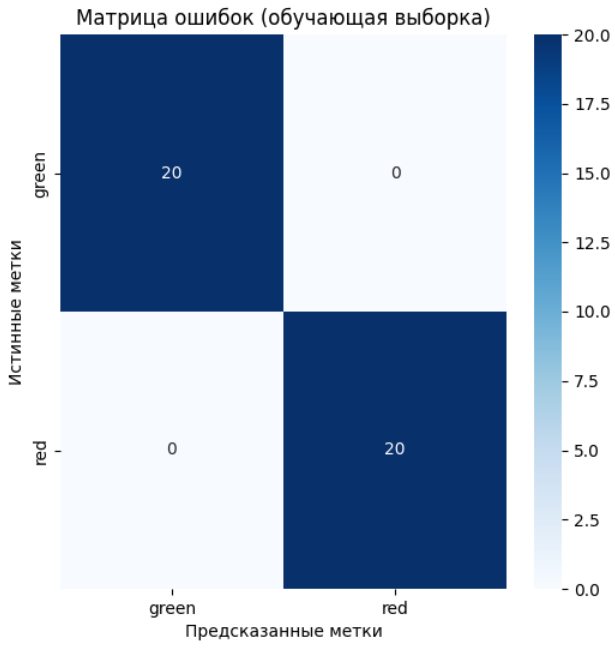
Вывод: наибольшая точность достигается при использовании евклидова расстояния при 3-х соседях. Это объясняется тем, что евклидово расстояние хорошо отражает "естественную" геометрическую близость точек в пространстве признаков. На всех метриках наибольшая точность находится около 4-х соседей. Для классификации этого экземпляра RI =1.516 Na =11.7 Mg =1.01 Al =1.19 Si =72.59 K=0.43 Ca

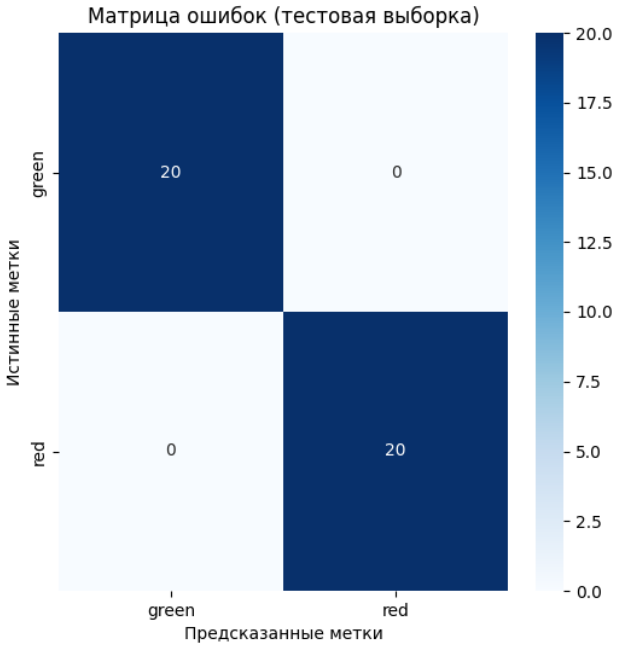
=11.44 Ba =0.02 Fe =0.1 я выбрал евклидово расстояние и 3-х ближайших соседей в связи с наибольшей точностью. Классификатор отнес данный экземпляр ко 2-ому классу.

4. Постройте классификаторы на основе метода опорных векторов для наборов данных из файлов svmdataN.txt и svmdataNtest.txt, где N – индекс задания:
    a. Постройте алгоритм метода опорных векторов с линейным ядром. Визуализируйте разбиение пространства признаков на области с помощью полученной модели. Выведите количество полученных опорных векторов, а также матрицу ошибок классификации на обучающей и тестовой выборках.

    Количество опорных векторов: 6

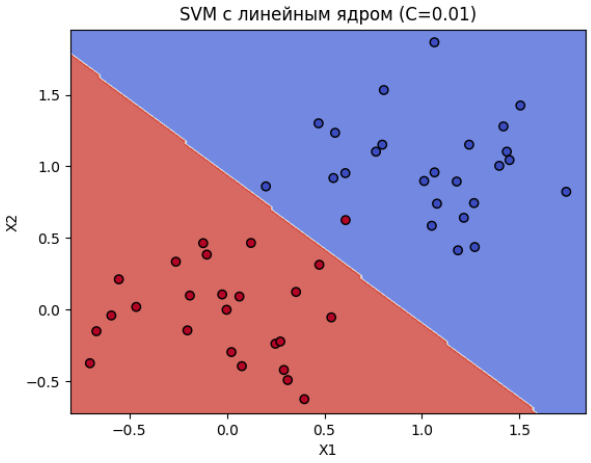






Вывод: данные хорошо классифицируются при использовании линейного ядра, это видно на графике, а также это подтверждают матрицы ошибок для обучающей и тестовой выборок, в которых нет ни одной ошибки классификации.

b. Постройте алгоритм метода опорных векторов с линейным ядром. Добейтесь нулевой ошибки сначала на обучающей выборке, а затем на тестовой, путем изменения штрафного параметра. Выберите оптимальное значение данного параметра и объясните свой выбор. Всегда ли нужно добиваться минимизации ошибки на обучающей выборке?

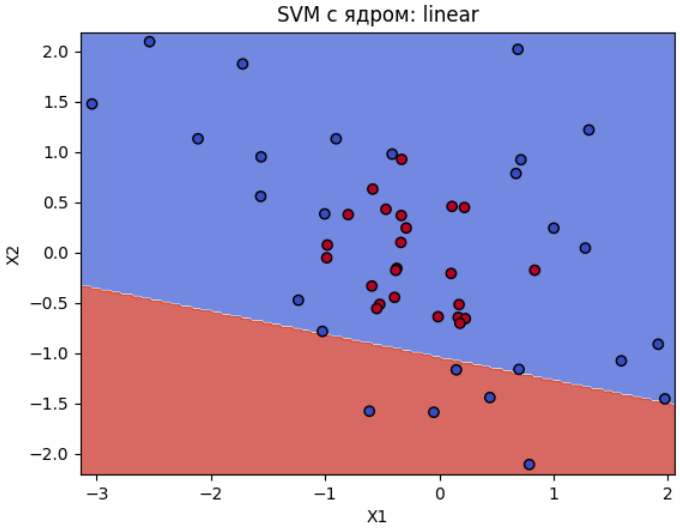



```
C = 0.01: Точность на обучающей выборке = 0.98, Точность на тестовой выборке = 1.0
Количество опорных векторов: 50
C = 0.1: Точность на обучающей выборке = 0.98, Точность на тестовой выборке = 1.0
Количество опорных векторов: 28
C = 1: Точность на обучающей выборке = 0.98, Точность на тестовой выборке = 1.0
Количество опорных векторов: 11
C = 10: Точность на обучающей выборке = 0.98, Точность на тестовой выборке = 1.0
Количество опорных векторов: 4
C = 100: Точность на обучающей выборке = 0.98, Точность на тестовой выборке = 1.0
Количество опорных векторов: 4
C = 1000: Точность на обучающей выборке = 1.0, Точность на тестовой выборке = 0.94
Количество опорных векторов: 3
```

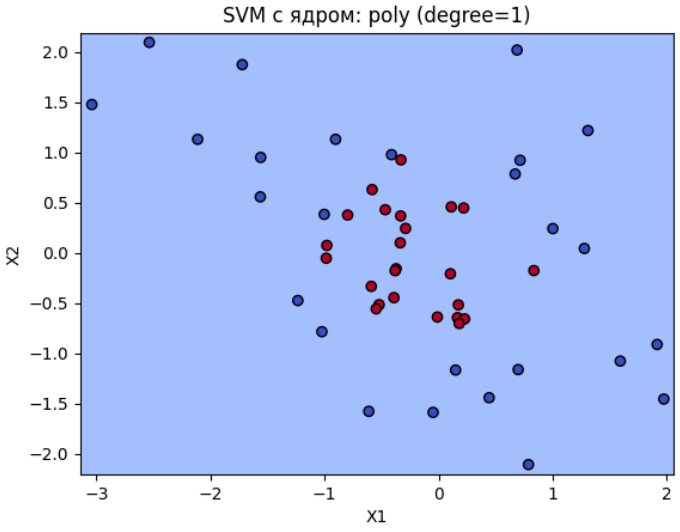
Вывод: наибольшая точность на тестовой выборке достигается при C=0.01..100. Оптимальное значение C=0.1 обеспечивает баланс между способностью модели улавливать закономерности и устойчивостью к шумам в данных

c. Постройте алгоритм метода опорных векторов, используя различные ядра (линейное, полиномиальное степеней 1-5, сигмоидальная функция, гауссово). Визуализируйте разбиение пространства признаков на области с помощью полученных моделей. Сделайте выводы.

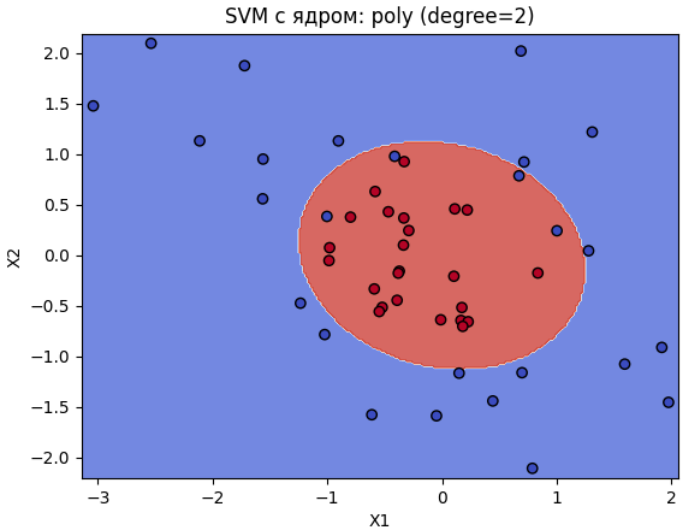
- Линейное (точность на тестовой выборке: 0.42)



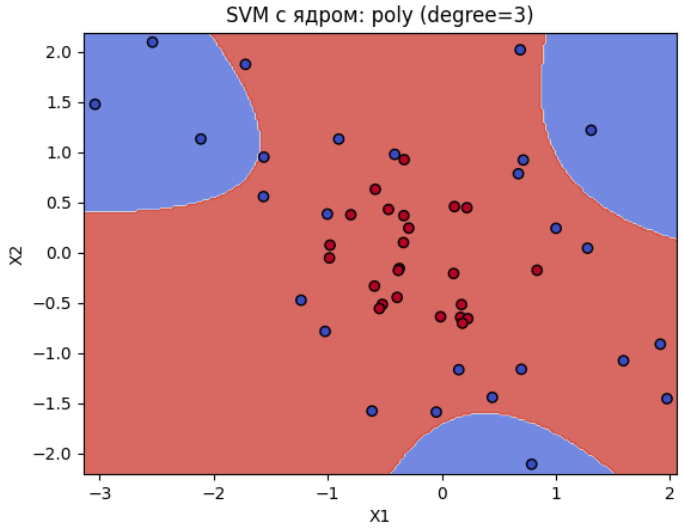
- Полиномиальное степени 1 (точность на тестовой выборке: 0.58)



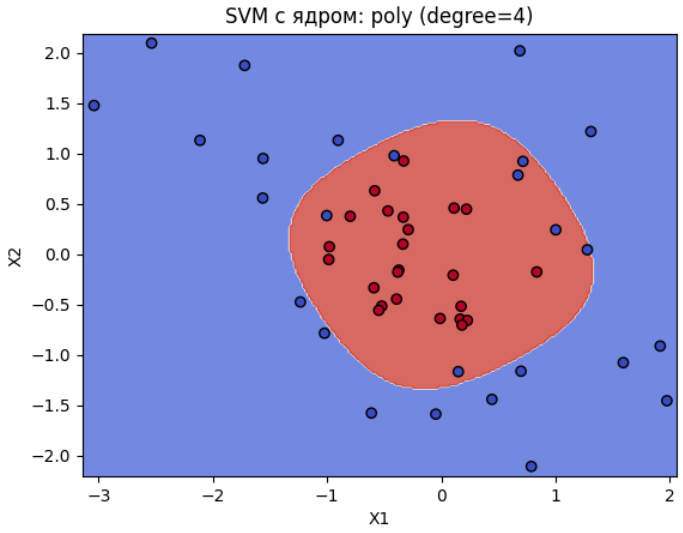
- Полиномиальное степени 2 (точность на тестовой выборке: 0.84)



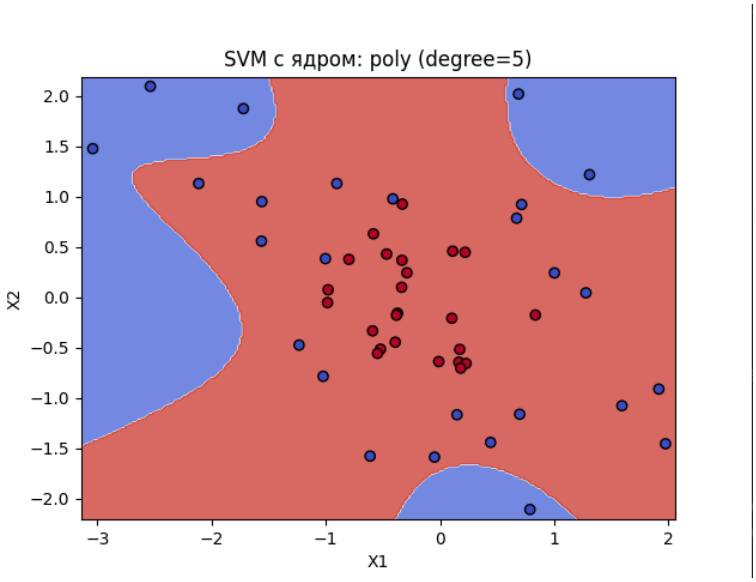
- Полиномиальное степени 3 (точность на тестовой выборке: 0.54)



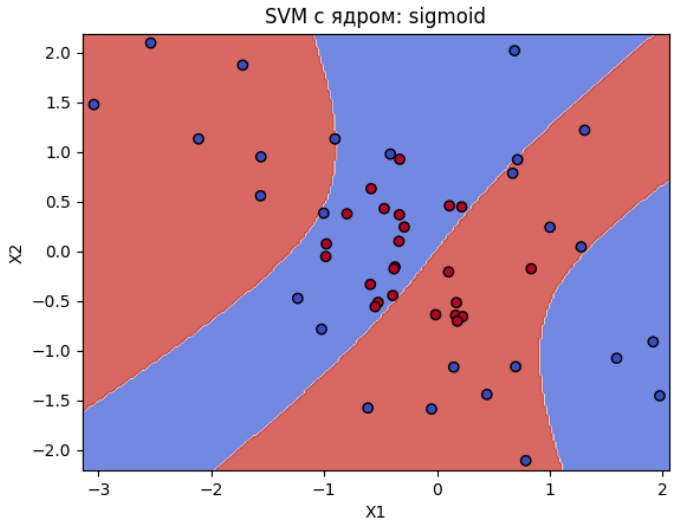
- Полиномиальное степени 4 (точность на тестовой выборке: 0.80)



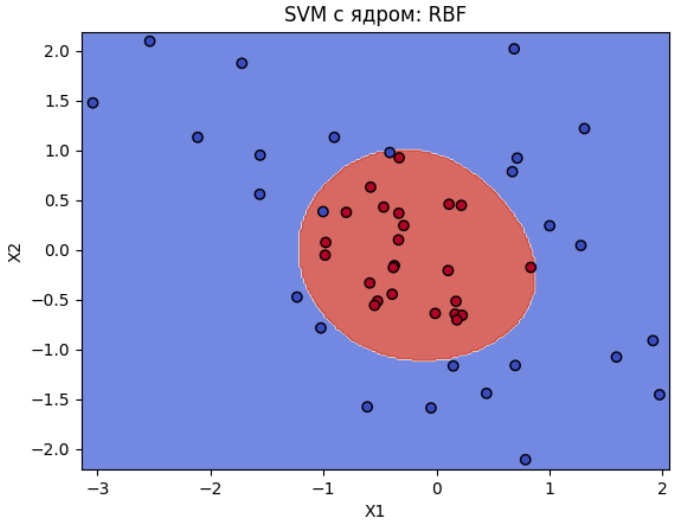
- Полиномиальное степени 5 (точность на тестовой выборке: 0.44)



- Сигмоидальная функция (точность на тестовой выборке: 0.78)



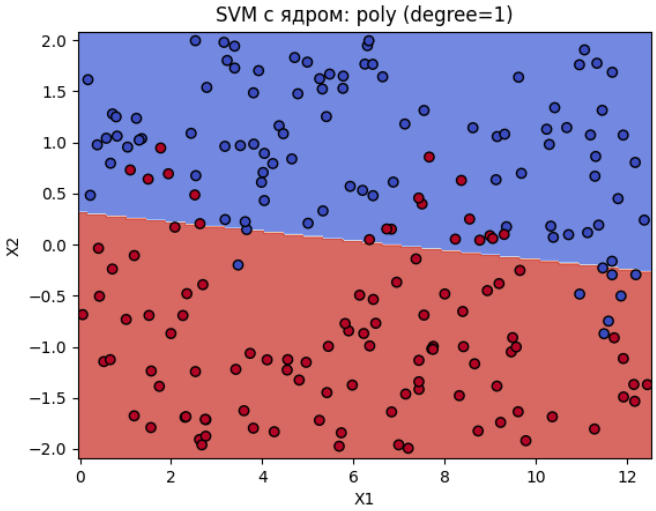
- Гауссово (точность на тестовой выборке: 0.94)



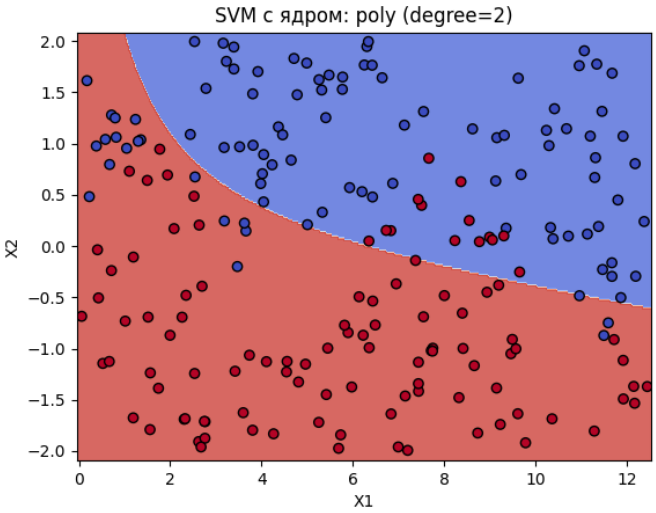
Вывод: согласно результатам анализа, полиномиальные ядра чётных степеней и гауссово ядро демонстрируют наилучшую эффективность на данной выборке. Остальные ядра показывают значительно более низкую точность классификации. Однако стоит учитывать, что высокая точность на обучающих данных может быть следствием переобучения, особенно для сложных моделей. Это может ухудшать их обобщающую способность на новых данных.

d. Постройте алгоритм метода опорных векторов, используя различные ядра (полиномиальное степеней 1-5, сигмоидальная функция, гауссово). Визуализируйте разбиение пространства признаков на области с помощью полученных моделей. Сделайте выводы

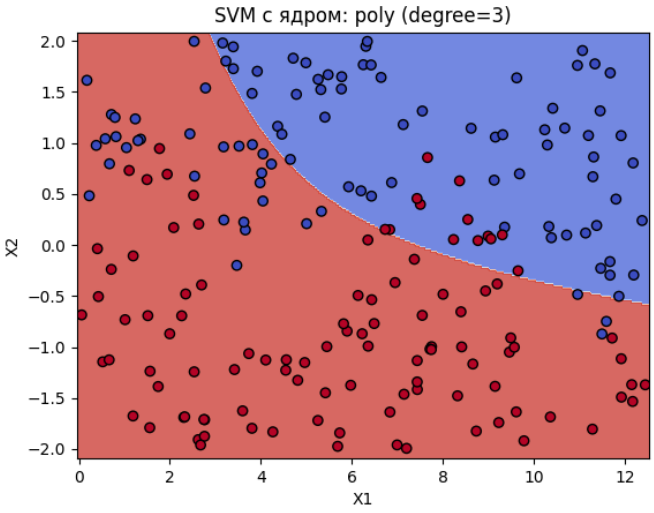
- Полиномиальное степени 1 (точность на тестовой выборке: 0.85)



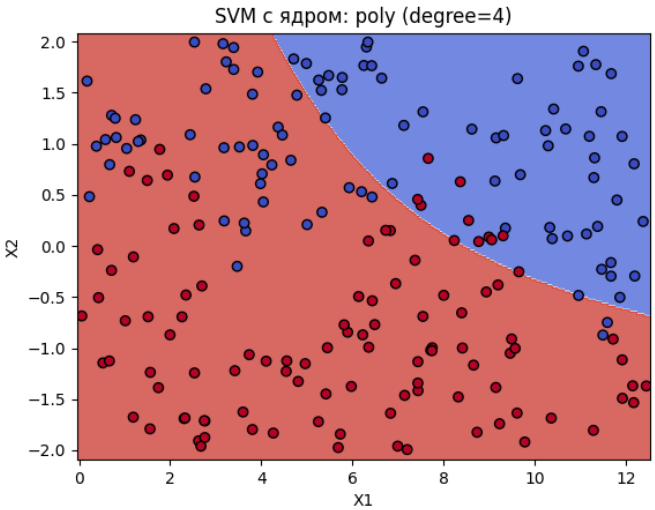
- Полиномиальное степени 2 (точность на тестовой выборке: 0.865)



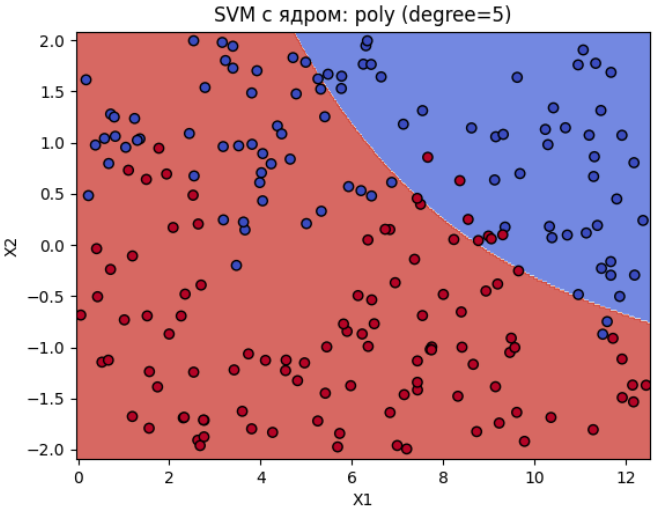
- Полиномиальное степени 3 (точность на тестовой выборке: 0.79)



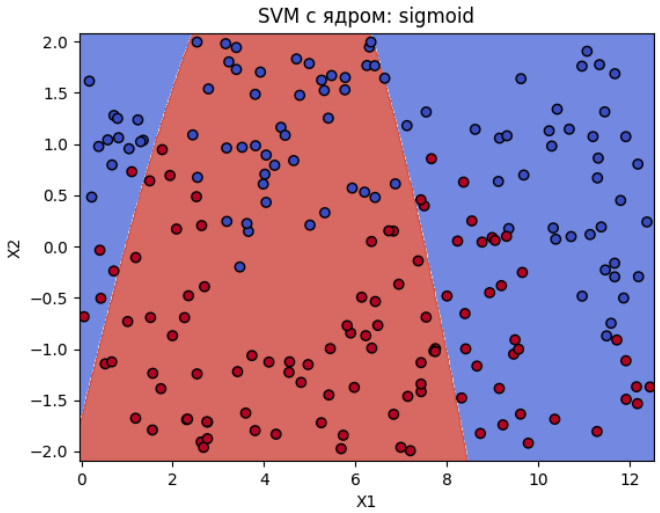
- Полиномиальное степени 4 (точность на тестовой выборке: 0.775)



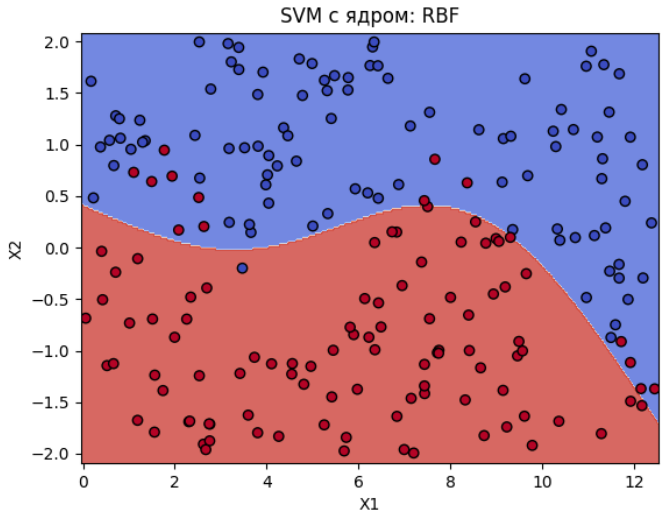
- Полиномиальное степени 5 (точность на тестовой выборке: 0.745)



- Сигмоидальная функция (точность на тестовой выборке: 0.585)



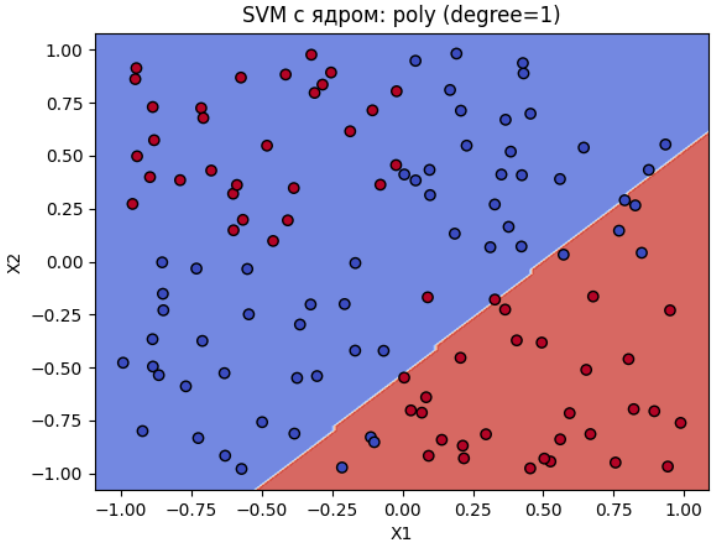
- Гауссово (точность на тестовой выборке: 0.895)



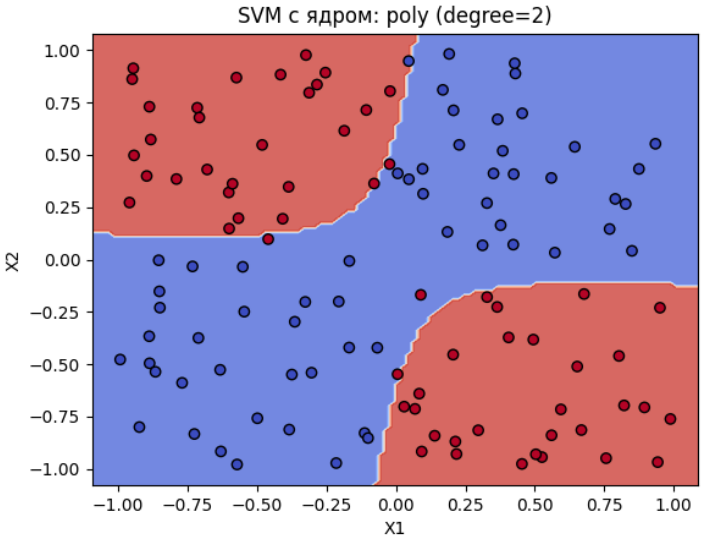
Вывод: согласно результатам анализа, полиномиальные ядра 1-ой и 2-ой степеней и гауссово ядро демонстрируют наилучшую точность на данной выборке. Остальные ядра показывают более низкую точность классификации. Однако стоит учитывать, что высокая точность на обучающих данных может быть следствием переобучения, особенно для сложных моделей. Это может ухудшать их обобщающую способность на новых данных.

e. Постройте алгоритм метода опорных векторов, используя различные ядра (полиномиальное степеней 1-5, сигмоидальная функция, гауссово). Изменяя значение параметра ядра (гамма), продемонстрируйте эффект переобучения, выполните при этом визуализацию разбиения пространства признаков на области.

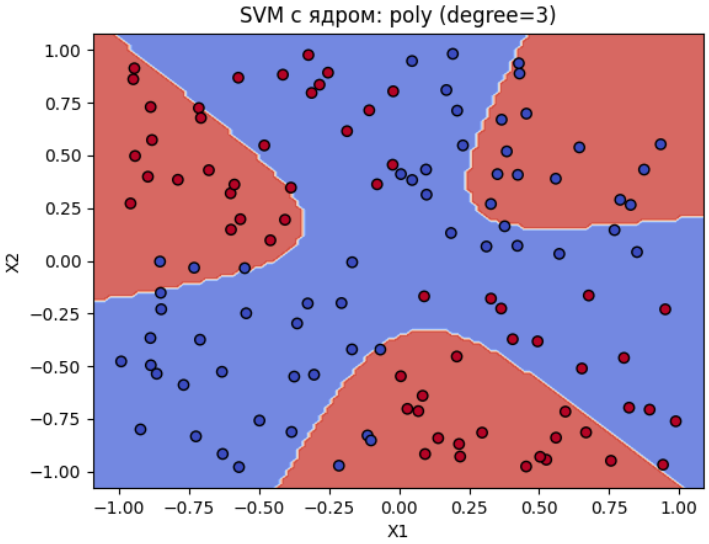
- Полиномиальное степени 1 (точность на тестовой выборке: 0.65)



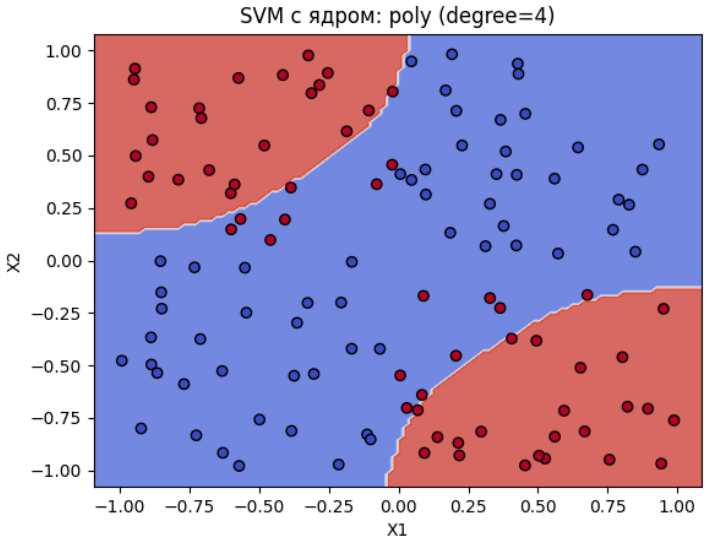
- Полиномиальное степени 2 (точность на тестовой выборке: 0.917)



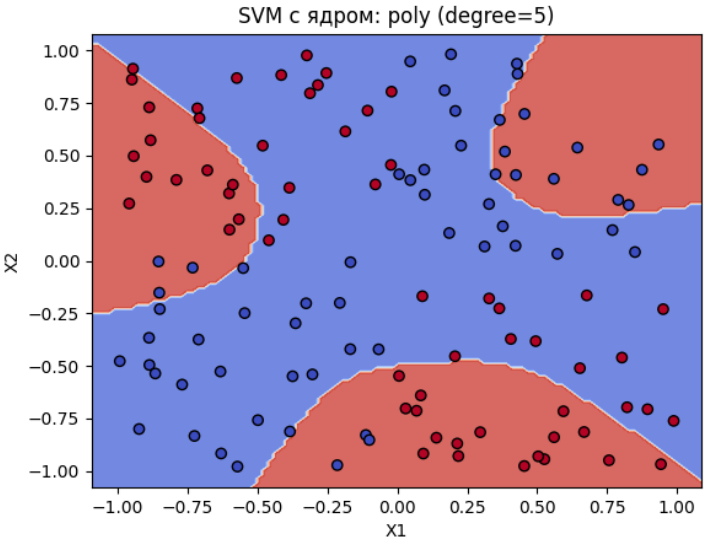
- Полиномиальное степени 3 (точность на тестовой выборке: 0.508)



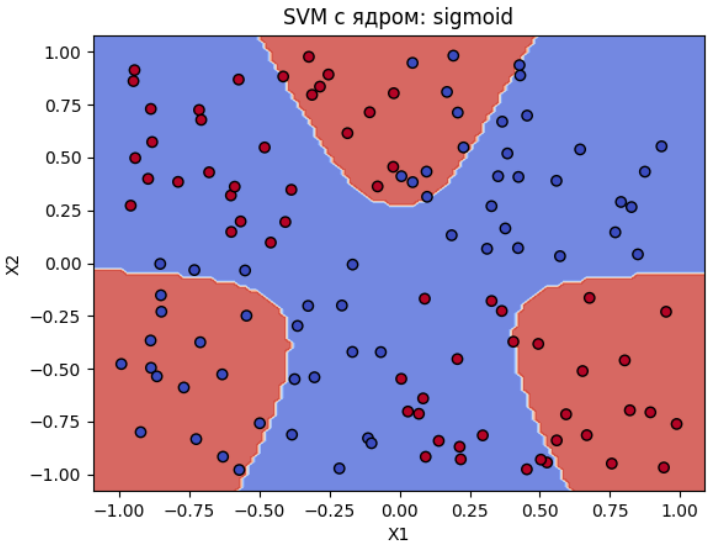
- Полиномиальное степени 4 (точность на тестовой выборке: 0.84)



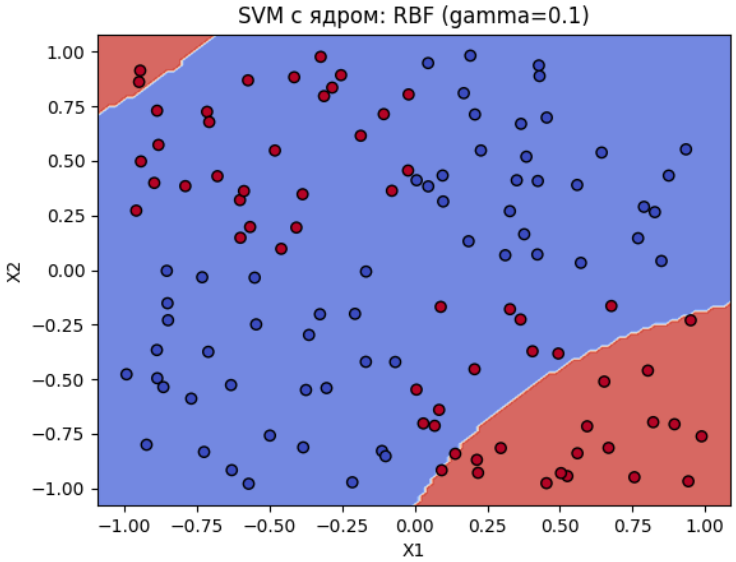
- Полиномиальное степени 5 (точность на тестовой выборке: 0.508)



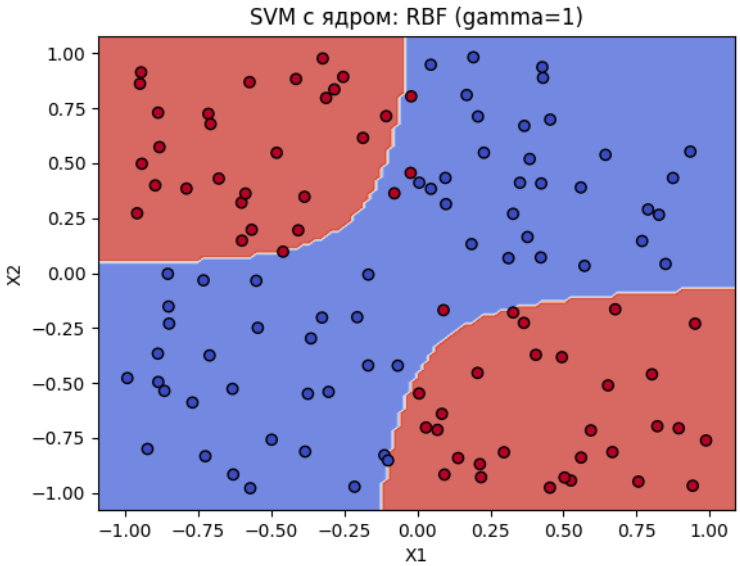
- Сигмоидальная функция (точность на тестовой выборке: 0.517)



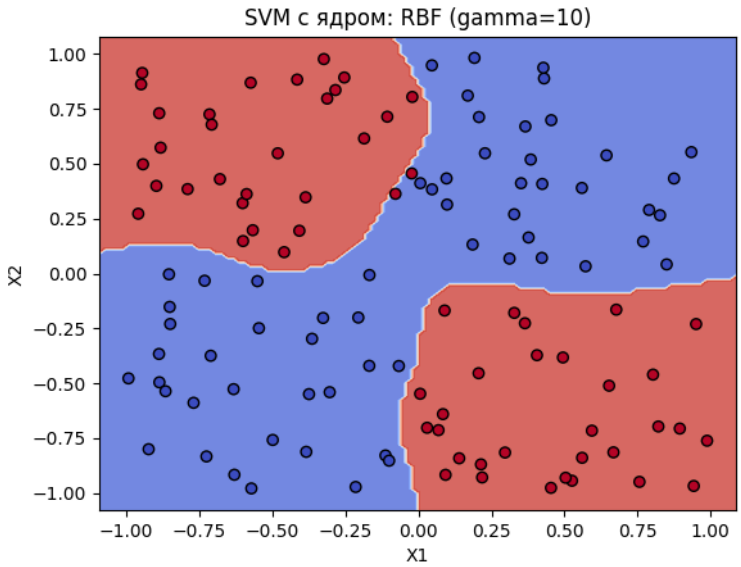
- Гауссово
  - Гамма = 0.1 (точность на тестовой выборке: 0.625)



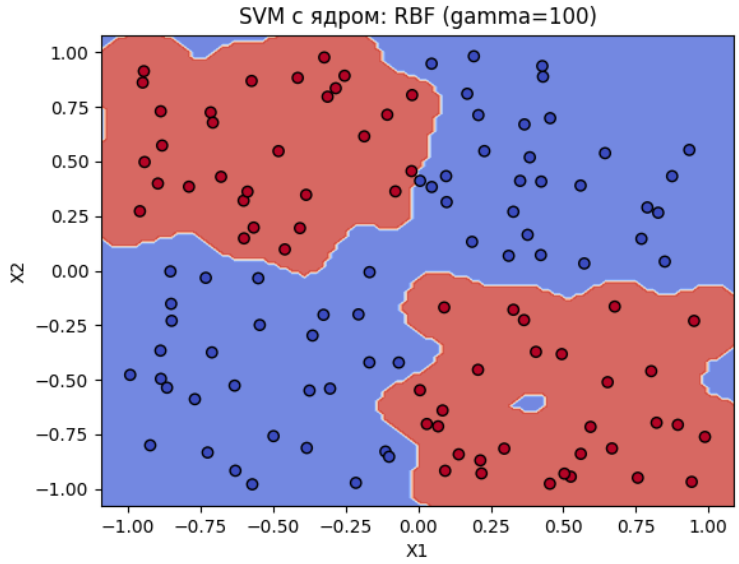
  - Гамма = 1 (точность на тестовой выборке: 0.917)



- Гамма = 10 (точность на тестовой выборке: 0.925)



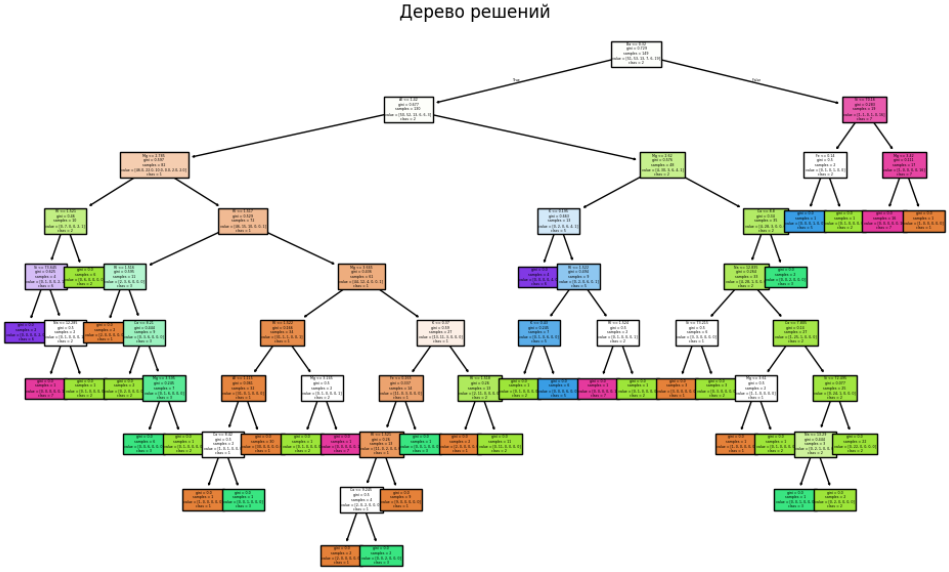
- Гамма = 100 (точность на обучающей выборке: 1, точность на тестовой выборке: 0.9083)



Вывод: согласно результатам анализа, полиномиальные ядро 4-ой степени и гауссово ядро с гаммами от 1 до 100 демонстрируют наилучшую точность на данной выборке. Остальные ядра показывают более низкую точность классификации. Однако стоит учитывать, что высокая точность на обучающих данных может быть следствием переобучения, особенно для сложных моделей. Это может ухудшать их обобщающую способность на новых данных. Также стоит отметить, что увеличивая гамму, мы увеличиваем обобщающую способность модели, тем самым увеличивая вероятность переобучения. Гауссово ядро с гаммой 0.1 имеет недостаточную обобщающую способность, а гауссово ядро с гаммой 100 имеет явные признаки переобучения, так как классифицирующее области сильно подстраиваются под данные. Именно поэтому гауссово ядро с гаммой 100 на обучающей выборке мы имеем 100% точность классификации, а тестовых данных уже 90.8%.

5. Постройте классификаторы для различных данных на основе деревьев решений:
    a. Загрузите набор данных Glass из файла glass.csv. Постройте дерево классификации для модели, предсказывающей тип (Type) по остальным признакам. Визуализируйте результирующее дерево решения. Дайте интерпретацию полученным результатам. Является ли построенное дерево избыточным? Исследуйте зависимость точности классификации от критерия расщепления, максимальной глубины дерева и других параметров по вашему усмотрению.

- Избыточное дерево решений (Точность: 0.65)



- Улучшенное дерево решений (Точность: 0.74)

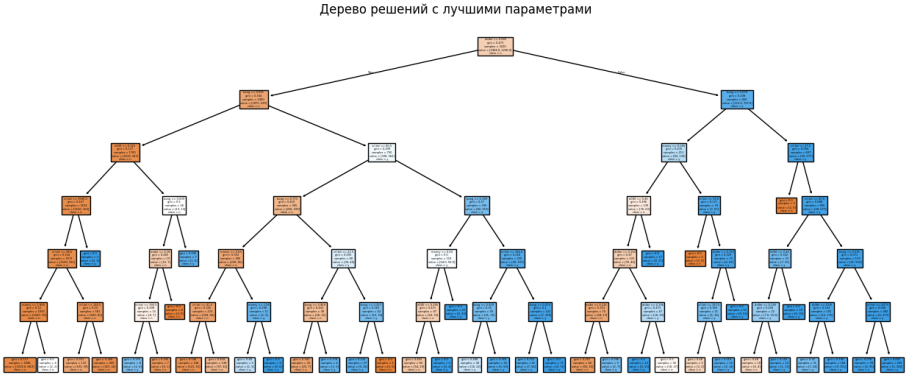


Вывод: в ходе выполнения задания был проведен комплексный анализ набора данных Glass с использованием деревьев решений. После загрузки и предварительной обработки данных было построено исходное дерево классификации, которое продемонстрировало достаточно высокую точность предсказания типов стекла, однако визуальный анализ структуры дерева выявил признаки избыточности и потенциального переобучения модели. Это проявлялось в чрезмерно глубокой и разветвленной структуре дерева, стремящейся чрезмерно точно подогнаться под обучающие данные. Для оптимизации модели был проведен тщательный подбор параметров с использованием GridSearchCV, который позволил определить оптимальные значения критерия расщепления, максимальной глубины дерева и других ключевых параметров. В результате оптимизации удалось достичь баланса между точностью

классификации и сложностью модели, что подтвердилось улучшением показателей на тестовой выборке. Полученные результаты наглядно демонстрируют важность корректной настройки параметров дерева решений для решения конкретной задачи классификации.

b. Загрузите набор данных spam7 из файла spam7.csv. Постройте оптимальное, по вашему мнению, дерево классификации для параметра yesno. Объясните, как был осуществлён подбор параметров. Визуализируйте результирующее дерево решения. Определите наиболее влияющие признаки. Оцените качество классификации.

- Оптимизированное дерево решений (Точность: 0.86)



Вывод: использование GridSearchCV с кросс-валидацией позволило определить оптимальные параметры модели: критерий расщепления, максимальная глубина, с минимальным количеством образцов для разделения узлов и в терминальных узлах. Анализ важности признаков выявил, что наибольший вклад в классификацию вносят критерий расщепления и максимальная глубина, что соответствует логике определения спама. Полученные результаты свидетельствуют о практической применимости модели для фильтрации спама.

6. Загрузите набор данных из файла bank_scoring_train.csv. Это набор финансовых данных, характеризующий физических лиц. Целевым столбцом является «SeriousDlqin2yrs», означающий, ухудшится ли финансовая ситуация у клиента. Постройте систему по принятию решения о выдаче или невыдаче кредита физическому лицу. Сделайте как минимум 2 варианта системы на основе различных классификаторов. Подберите подходящую метрику качества работы системы исходя из специфики задачи и определите, принятие решения какой системой сработало лучше на bank_scoring_test.csv.

В качестве классификаторов я выбрал наивный Байесовский метод и метод k-ближайших соседей (3 соседей).

- Наивный Байесовский метод

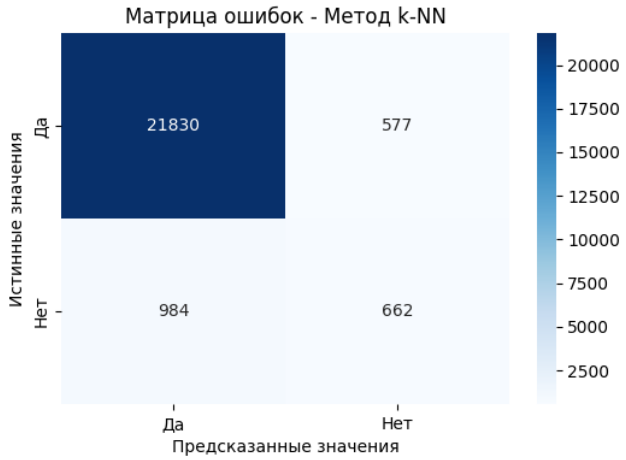


Точность: 0.93

F1-мера: 0.0529

Recall: 0.03

- Метод k-ближайших соседей (3 соседа)



Точность: 0.9351

F1-мера: 0.4589

Recall: 0.4

Вывод: Проведя сравнительный анализ двух моделей классификации для задачи выдачи кредитов, можно сделать следующие выводы. Наивный Байесовский классификатор продемонстрировал высокую точность (93%) на тестовой выборке, однако этот показатель оказался обманчивым при более детальном рассмотрении. Основная проблема данной модели заключается в крайне низкой полноте (recall = 0.03) для класса дефолтщиков (1.0), что означает, что модель пропускает 97% потенциально проблемных заемщиков. При этом F1-мера составляет 0.05, что свидетельствует о полной непригодности данной модели для практического применения в банковской сфере.

Метод k-ближайших соседей показал существенно лучшие результаты по всем ключевым метрикам. При сравнимой общей точности (93.5%) эта модель демонстрирует значительно более высокую полноту (recall = 0.40) для класса дефолтщиков, что означает выявление 40% потенциально проблемных заемщиков против 3% у Наивного Байеса. F1-мера достигла 0.46, что почти в 10 раз лучше показателей первой модели.

Однако даже лучшая модель обнаруживает лишь 40% проблемных заемщиков, что указывает на необходимость дальнейшего совершенствования системы.